

Dataset do grupo FinCheck

O conjunto de dados foi construído a partir da integração e do processamento de bases de dados preexistentes, contendo notícias classificadas quanto à sua veracidade. A partir dessas bases, foram selecionadas as notícias relacionadas ao domínio financeiro, utilizando técnicas de processamento de linguagem natural e representações vetoriais obtidas por meio do modelo BERTimbau.

Descrição das colunas:

- Noticia: texto das notícias relacionadas à finanças;
- Rotulo: classificação da notícia como "fake" (falsa) ou "true" (verdadeira);
- score_financas: medida de similaridade semântica entre a notícia e as referências relacionadas ao domínio financeiro, definida como o maior valor de similaridade do cosseno obtido entre o embedding da notícia e os embeddings das frases de referência.

Bases de dados utilizadas:

- <https://github.com/roneysco/Fake.br-Corpus>
- <https://huggingface.co/datasets/recogna-nlp/FakeRecogna>

```
In [2]: import pandas as pd
```

```
In [3]: df = pd.read_csv("noticias_financas.csv")  
  
df.head()
```

Out[3]:

	Noticia	Rotulo	score_financas
0	Dr. Ray peita Bolsonaro, chama-o de "conservad...	fake	0.551157
1	Reinaldo Azevedo desmascarado pela Polícia Fed...	fake	0.553829
2	Relatório assustador do BNDES mostra dinheiro ...	fake	0.574246
3	PT diz que Lula não tem dinheiro para sobreviv...	fake	0.568083
4	Coodenador da Lava-Jato se revolta: "Aumento d...	fake	0.539498

In [6]: `df.info()`

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 19092 entries, 0 to 19091
Data columns (total 3 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Noticia          19092 non-null  object
1   Rotulo           19092 non-null  object
2   score_financas   19092 non-null  float64
dtypes: float64(1), object(2)
memory usage: 447.6+ KB
```

In [4]: `df["Rotulo"].value_counts()`

Out[4]:

Rotulo	
fake	11173
true	7919

Name: count, dtype: int64